2025 – 2026 Bahar Dönemi
YZM212 Makine Öğrenmesi Dersi
2. Laboratuvar Ödevi

Öğrenci Adı: Abdülbaki Bayır

Öğrenci Numarası: 24290050

Tarih: 15.03.2026

1. Bölüm Teorik Çözümler

n: Toplam gözlem(veri) sayısı. Caddede kaç farklı 1 dakikalık ölçümün yapıldığını belirten değişken.

k: Bir dakikada geçen araç sayısı.

k_i: i. Gözlemde ölçülen araç sayısı.

λ: Poisson dağılımının parametresi. Caddeden 1 dakikada geçen ortalama araç sayısı bulmaya çalıştığımız asıl "en iyi parametre tahmini" budur.

P(k| λ): Sistemin λ ortalamasına sahip olduğu bilindiğinde caddeden k araç geçme olasılığı.

P(k| λ) = $\frac{e^{-\lambda}.\lambda^{k}}{k!}$

L(λ): Likelihood(olabilirlik) fonksiyonu.

l(λ): Log-Likelihood(Log-olabilirlik) fonksiyonu.

Soru 1:

1. Adım: Likelihood Fonksiyonu (L(λ))

L(λ) = P(k_1 |λ) . P(k_2 |λ) . . . P(k_n |λ)

L(λ) = $\prod_{i=1}^{n} \frac{e^{-\lambda}.\lambda^{k_i}}{k_i!}$

2. Adım: Log-Likelihood Fonksiyonu (l(λ))

l(λ) = ln(L(λ)) = ln($\prod_{i=1}^{n} \frac{e^{-\lambda}.\lambda^{k_i}}{k_i!}$)

l(λ) = $\sum_{i=1}^{n} \ln(\frac{e^{-\lambda}.\lambda^{k_i}}{k_i!})$

l(λ) = $\sum_{i=1}^{n}(\ln(e^{-\lambda}) + \ln(\lambda^{k_i}) - \ln(k_i!))$

l(λ) = $\sum_{i=1}^{n}(- \lambda + k_i \ln(\lambda) - \ln(k_i!))$

l(λ) = -n λ + ln(λ)$\sum_{i=1}^{n} k_i$ - $\sum_{i=1}^{n} \ln(k_i\,!)$

3. Adım Türev Alma ve Sıfıra Eşitleme

Fonksiyonun λ'ya göre türevi alınır.

$\frac{d}{d\lambda}(-n\ \lambda) = -n$

$\frac{d}{d\lambda}(\ln(\lambda)) = \frac{1}{\lambda}$

$$\frac{d}{d\lambda}\left(\sum_{i=1}^{n} \ln(k_i\,!)\right) = 0$$

$\frac{d}{d\lambda}(l(\lambda)) = -n + \frac{1}{\lambda}\sum_{i=1}^{n} k_i$

$-n + \frac{1}{\lambda}\sum_{i=1}^{n} k_i = 0$

$$\frac{1}{\lambda}\sum_{i=1}^{n} k_i = n$$

$$\widetilde{\lambda_{MLE}} = \frac{1}{n}\sum_{i=1}^{n} k_i$$

Sonuç: $\widetilde{\lambda_{MLE}} = \frac{1}{n}\sum_{i=1}^{n} k_i$ ifadesi $\frac{\text{TÜM ARAÇ SAYILARININ TOPLAMI}}{\text{VERİ SAYISI}}$ olur ve bu bize Aritmetik Ortalamayı verir. İspatı yapılmıştır.

2. Bölüm Analiz ve Yorumlar

Soru 2:

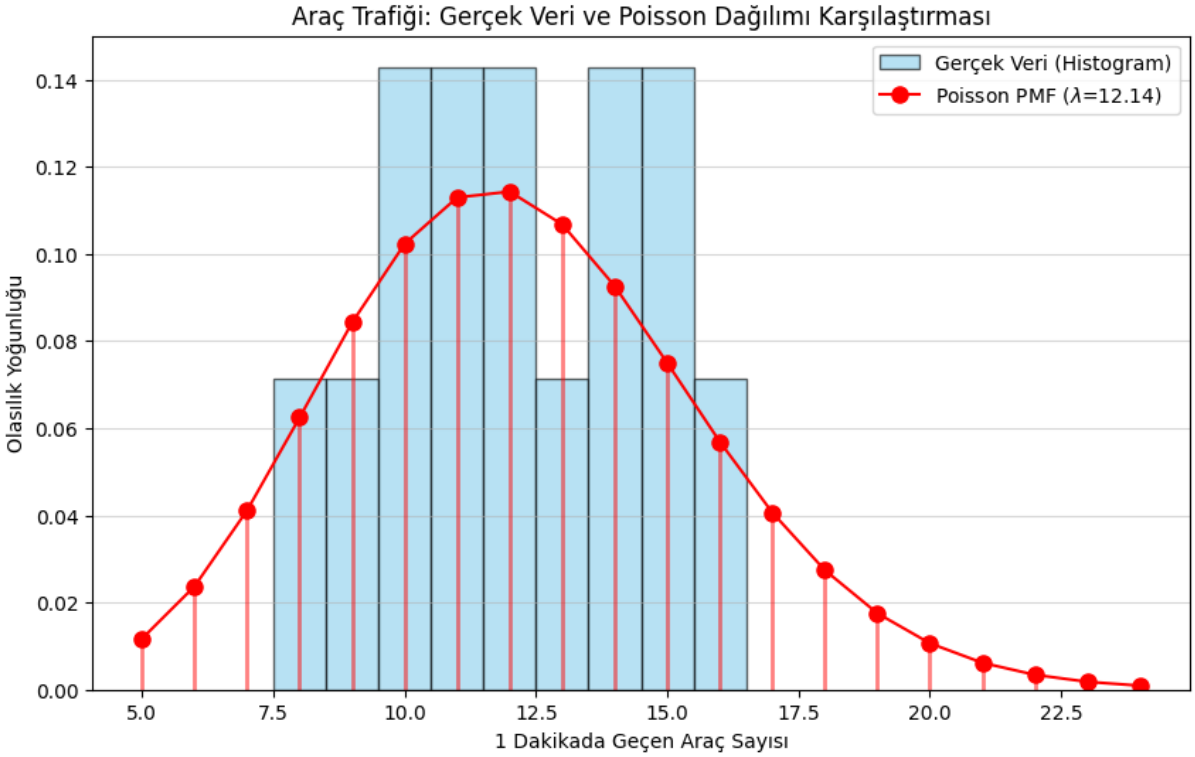

Grafik genel olarak incelendiğinde, MLE yöntemiyle hesaplanan teorik Poisson modelinin (kırmızı eğri) en yüksek olasılıklı bölgesi ile gerçek trafik verilerimizin (mavi histogram) genel yayılımı büyük ölçüde örtüşmektedir. Her iki dağılımın da ana merkezi 12 civarında toplanmış olup, caddedeki araç sayısının 8 ile 16 arasındaki genel karakteristiği model tarafından anlamlı bir şekilde yakalanmıştır.

Ancak daha detaylı bir analize girildiğinde, teorik modelin beklendiği üzere 12.14 etrafında kusursuz bir zirve yaptığı, gerçek veri setinde ise tam 12 noktasında mutlak bir zirve yerine yerel bir düşüş yaşandığı fark edilmektedir. Gözlemlerin 12'de yığılmak yerine daha çok 10-11 ve 14-15 araç bandında kümelendiği görülmektedir. Bu yerel farklılığın temel nedeni, elimizdeki gözlem sayısının (n=14) oldukça küçük olmasıdır. İstatistiksel olarak bu kadar küçük örneklem boyutlarında, doğal rastlamsallık (noise) sebebiyle gerçek verilerin teorik bir olasılık dağılımından bu tarz anlık ve yerel sapmalar göstermesi tamamen beklenen bir durumdur.

Sonuç: Örneklem boyutunun küçüklüğünden kaynaklanan bu anlık dalgalanmalara rağmen, verilerin merkez etrafında toplanma eğilimi ve genel yayılım aralığı dikkate alındığında; kurulan Poisson modelinin trafik verisini çok iyi temsil ettiği, gerçek verilere oldukça başarılı ve kabul edilebilir bir uyum (fit) sağladığı kanıtlanmıştır.

Soru 3:

MLE yöntemi (dolayısıyla ortalama) bu uç değerden nasıl etkilenir?

Poisson dağılımı için Maximum Likelihood Estimation (MLE) tahmini, verilerin aritmetik ortalamasına eşittir. Aritmetik ortalamanın en büyük zayıflığı ise aykırı değerlere (outliers) karşı son derece hassas ve kırılgan olmasıdır. Orijinal veri setimizde 14 gözlemin toplamı 170, λ ortalamamız ise yaklaşık 12.14'tü. Sisteme yanlışlıkla "200" değerinde tek bir hatalı veri eklendiğinde, toplamımız bir anda 370'e, veri sayımız (n) ise 15'e çıkar. Yeni λ değerimiz

$\frac{370}{15} \approx 24.66$ olur. Görüldüğü gibi, sadece tek bir hatalı gözlem, tüm caddenin trafik yoğunluğu tahminini anında iki katına çıkarmış ve kurduğumuz istatistiksel modeli tamamen bozmuştur.

Bu durum, belediyenin trafik planlamasında (örneğin yol genişletme kararı) nasıl bir hataya yol açabilir?

Eğer belediyenin ulaşım departmanı, veriyi önceden temizlemeden (outlier analizi yapmadan) doğrudan bu hatalı MLE sonucuna göre hareket ederse, caddede inanılmaz bir trafik sıkışıklığı yaşandığını ve kapasitenin iki kat aşıldığını zannedecektir.

Bu durum Gereksiz Yatırım ve Kaynak İsrafı, Halkın Mağduriyeti ve Fırsat Maliyeti gibi sorunlara yol açabilir.

Bu senaryo, makine öğrenmesi ve veri bilimi projelerinde "Garbage In, Garbage Out" kuralının en net kanıtıdır. Modellerimizi eğitmeden ve MLE gibi tahminleyicileri çalıştırmadan önce, veriyi görselleştirmek ve aykırı değerleri (outliers) tespit edip temizlemek, hayati derecede kritik bir ön işlemdir.

Kaynakça:

Bu ödev hazırlanırken ödev yönergesi dışında harici bir kaynak kullanılmamıştır.